

Relatório de Apresentação do Projeto para Equipe Técnica de Automação e Monitoramento

Foi realizada uma apresentação informal do projeto “Sistema de Recomendação de Filmes Baseado em Embeddings e Similaridade Semântica” para uma equipe composta por aproximadamente cinco profissionais da área de tecnologia, atuantes em automação e monitoramento de equipamentos de telecomunicações utilizados em agências bancárias. A equipe possui experiência principalmente em automações, monitoramento de infraestrutura distribuída, redes, telecomunicações e utilização de serviços AWS em ambientes produtivos.

Durante a apresentação, foram abordados o contexto do projeto, os datasets utilizados (IMDb e MovieLens), a metodologia aplicada para construção do perfil do usuário por meio de embeddings, os resultados obtidos, as métricas de avaliação e os ajustes realizados no pipeline do modelo.

A equipe tem forte conhecimento técnico em automação, telecom e arquitetura em nuvem, portanto os conceitos relacionados à Ciência de Dados, Processamento de Linguagem Natural (NLP) e sistemas de recomendação eram relativamente novos para parte dos participantes. Por esse motivo, houve grande interesse e curiosidade em compreender como ocorre o processo de transformação de dados brutos em informações utilizáveis para modelos analíticos.

As partes do trabalho que mais geraram interesse foram o processo de limpeza e preparação dos dados, incluindo remoção de ruídos textuais, normalização, tratamento de informações e construção de representações adequadas para análise.

Além disso, o conceito de embeddings gerou bastante curiosidade, principalmente pelo fato de permitir transformar textos em vetores numéricos capazes de representar significado semântico. Houve questionamentos sobre como avaliações textuais de usuários podem ser convertidas em embeddings e posteriormente comparadas com outros vetores representando filmes, possibilitando calcular similaridade semântica e gerar recomendações.

A equipe também quis entender melhor como uma análise inicialmente composta por linguagem natural pode evoluir para representações vetoriais comparáveis matematicamente, permitindo medir proximidade entre preferências do usuário e características dos filmes.

Também houve discussões sobre escalabilidade e implantação em ambiente produtivo.

Considerando a experiência da equipe com AWS, foram levantadas possibilidades de arquitetura para operacionalizar o sistema utilizando serviços gerenciados da plataforma.

Entre as alternativas discutidas, destacou-se uma arquitetura composta por:

- Amazon S3 e CloudFront para hospedagem do front-end;
- API Gateway para exposição de endpoints;
- AWS Lambda para processamento das requisições;
- Amazon SageMaker para hospedagem do modelo de Machine Learning;
- Amazon DynamoDB ou Amazon S3 para armazenamento de embeddings e histórico;
- CloudWatch para monitoramento e observabilidade.

Como a equipe faz uso frequente de AWS nas atividades relacionadas à automação e monitoramento de equipamentos distribuídos, não poderia faltar uma discussão sobre esse tópico.

Além disso, a equipe já possui experiência prática com aplicações de Inteligência Artificial em ambiente produtivo, incluindo soluções voltadas para sumarização automática de informações operacionais e apoio à análise de incidentes em cenários onde automações tradicionais não são suficientes.

Houve bastante interesse em compreender diferenças entre essas aplicações e abordagens relacionadas à Ciência de Dados, Processamento de Linguagem Natural (NLP) e sistemas de recomendação. A discussão destacou principalmente como técnicas baseadas em embeddings permitem transformar dados textuais em representações vetoriais comparáveis matematicamente, ampliando possibilidades de análise além dos casos de uso já explorados pela equipe.

De forma geral, a apresentação gerou discussões além do escopo inicial do projeto, despertando interesse sobre aplicações práticas de Ciência de Dados em ambientes corporativos. Observei curiosidade não apenas sobre o resultado final do sistema de recomendação, mas principalmente sobre o processo completo:

coleta dos dados → limpeza → transformação em embeddings → comparação semântica → recomendação → implantação em arquitetura escalável