

UNIVERSIDADE PRESBITERIANA MACKENZIE
FACULDADE DE COMPUTAÇÃO E INFORMÁTICA
CURSO DE CIÊNCIA DE DADOS

ALEXANDRE ZAMARION CEPEDA
FELIPE CLARINDO
THIAGO GODEGUESI
VICTÓRIA FORTES

**SISTEMA DE RECOMENDAÇÃO DE FILMES BASEADO EM EMBEDDINGS E
SIMILARIDADE SEMÂNTICA**

SÃO PAULO
2026

ALEXANDRE ZAMARION CEPEDA
FELIPE CLARINDO
THIAGO GODEGUESI
VICTÓRIA FORTES

**SISTEMA DE RECOMENDAÇÃO DE FILMES BASEADO EM EMBEDDINGS E
SIMILARIDADE SEMÂNTICA**

Trabalho acadêmico apresentado como requisito parcial para aprovação na disciplina Projeto Aplicado III do Curso de Ciência de Dados da Faculdade de Computação e Informática da Universidade Presbiteriana Mackenzie.

Orientador(a): Prof(a). Dr(a). Carolina Toledo Ferraz

SÃO PAULO
2026

AGRADECIMENTOS

Agradecemos, primeiramente, à Universidade Presbiteriana Mackenzie e ao corpo docente da Faculdade de Computação e Informática por prover a base de conhecimento essencial para a nossa formação científica. Aos nossos familiares e amigos, pelo apoio incondicional, paciência e incentivo durante as longas jornadas de desenvolvimento deste projeto. À nossa orientadora, pelas correções minuciosas, direcionamentos precisos na concepção do pipeline de dados e insights fundamentais para a evolução lógica deste experimento científico.

RESUMO

Este trabalho aborda a evolução e a relevância dos sistemas de recomendação no contexto de consumo massivo de mídia em plataformas digitais de streaming. O principal desafio reside em mitigar as limitações dos sistemas tradicionais baseados em regras rígidas ou tags textuais simples, que falham em capturar nuances subjetivas de linguagem natural. O sistema proposto implementa uma prova de conceito de um modelo de recomendação baseado em conteúdo que integra dados textuais subjetivos com metadados estruturados de qualidade. Utilizando o Sentence Transformers por meio do modelo pré-treinado 'all-MiniLM-L6-v2', resenhas textuais positivas extraídas do dataset IMDb 50K foram transformadas em vetores densos de 384 dimensões para a construção do perfil semântico consolidado do usuário. A similaridade semântica entre o perfil e o catálogo estruturado do MovieLens foi calculada através da métrica de similaridade cosseno. O modelo baseline inicial alcançou uma similaridade média de 0,51 e uma Precision@10 estável de 0,6. Para aumentar a robustez pragmática, o pipeline foi ajustado pela inclusão de filtros restritivos baseados no histórico comportamental (nota média maior ou igual a 3,5 e contagem mínima de 20 avaliações). O modelo ajustado resultou em uma redução da similaridade média matemática para 0,48, porém mantendo a Precision@10 em 0,6. Os resultados indicam que o sacrifício de uma fração de proximidade teórica textual elimina a indicação de títulos de nicho mal avaliados, otimizando de maneira robusta a qualidade real das recomendações.

Palavras-chave: Sistemas de Recomendação. Processamento de Linguagem Natural. Sentence Transformers. Similaridade Semântica. Inteligência Artificial.

ABSTRACT

This paper addresses the evolution and relevance of recommender systems within the context of massive media consumption on digital streaming platforms. The core challenge lies in mitigating the limitations of traditional systems based on rigid rules or simple text tags, which fail to capture subjective nuances in natural language. The proposed system implements a content-based recommendation proof of concept that integrates subjective textual data with structured quality metadata. Using Sentence Transformers via the pre-trained 'all-MiniLM-L6-v2' model, positive text reviews extracted from the IMDb 50K dataset were transformed into dense 384-dimensional vectors to construct the user's consolidated semantic profile. The semantic similarity between the profile and the MovieLens structured catalog was calculated using the cosine similarity metric. The initial baseline model achieved an average similarity of 0.51 and a stable Precision@10 of 0.6. To enhance pragmatic robustness, the pipeline was adjusted by incorporating restrictive filters based on historical behavioral records (average rating greater than or equal to 3.5 and a minimum count of 20 ratings). The adjusted model resulted in a reduction of the mathematical average similarity to 0.48, while maintaining Precision@10 at 0.6. The results indicate that sacrificing a fraction of theoretical textual proximity eliminates the suggestion of poorly evaluated niche titles, robustly optimizing the real-world quality of recommendations.

Keywords: Recommender Systems. Natural Language Processing. Sentence Transformers. Semantic Similarity. Artificial Intelligence.

SUMÁRIO

1. INTRODUÇÃO.....	7
1.1 Contexto do Trabalho.....	7
1.2 Motivação.....	7
1.3 Justificativa.....	8
1.4 Objetivo Geral e Objetivos Específicos.....	8
1.4.1 Objetivo Geral.....	8
1.4.2 Objetivos Específicos.....	8
2. REFERENCIAL TEÓRICO.....	9
2.1 Sistemas de Recomendação.....	9
2.2 Recomendação Baseada em Conteúdo.....	9
2.3 Representação Vetorial e Embeddings.....	10
2.4 Sentence Transformers e Similaridade Semântica.....	10
2.5 Integração de Dados e Abordagem Proposta.....	10
2.6 Considerações sobre Prova de Conceito.....	11
3. METODOLOGIA.....	11
3.1 Definição do Problema e Objetivos.....	12
3.2 Coleta de Dados.....	13
3.2.1 Dataset IMDb 50K Movie Reviews.....	13
3.2.2 Dataset MovieLens.....	13
3.3 Pré-processamento e Limpeza dos Dados.....	13
3.4 Divisão dos Dados e Construção do Perfil do Usuário.....	14
3.5 Seleção e Implementação do Algoritmo.....	14
3.6 Treinamento do Modelo.....	14
3.7 Avaliação do Desempenho.....	15
3.8 Otimização e Ajustes.....	15
3.9 Implantação e Monitoramento.....	16
4. RESULTADOS.....	16
4.1 Resultados do Modelo Baseline.....	16
4.2 Resultados Após Ajustes do Modelo.....	17
4.3 Comparação entre Modelo Baseline e Modelo Ajustado.....	17

4.4 Análise das Métricas.....	19
4.4.1 Similaridade Média.....	19
4.4.2 Precision@10.....	19
4.5 Discussão dos Resultados.....	19
4.6 Limitações Observadas.....	20
5. CONCLUSÕES E TRABALHOS FUTUROS.....	20
5.1 Resumo dos Principais Resultados.....	20
5.2 Contribuições do Projeto.....	21
5.3 Limitações Identificadas.....	21
5.4 Impacto Prático.....	21
5.5 Trabalhos Futuros.....	22
5.5.1 Melhorias Técnicas.....	22
5.5.2 Testes e Validações Adicionais.....	22
5.5.3 Expansão dos Dados.....	22
5.5.4 Escalabilidade e Implantação.....	23
6. CONSIDERAÇÕES FINAIS.....	23
7. REFERÊNCIAS.....	23
8. APÊNDICES.....	24

1. INTRODUÇÃO

1.1 Contexto do Trabalho

Os sistemas de recomendação têm se tornado componentes fundamentais em plataformas digitais modernas, sendo amplamente utilizados em serviços de streaming, comércio eletrônico e redes sociais. Esses sistemas utilizam técnicas computacionais para sugerir conteúdos personalizados aos usuários com base em preferências, comportamentos anteriores ou características dos próprios itens.

Nesse contexto, plataformas como YouTube, Netflix, Spotify e Amazon empregam algoritmos de recomendação para melhorar a experiência do usuário, aumentar engajamento e facilitar a descoberta de conteúdos relevantes. O crescimento do volume de dados textuais gerados diariamente torna necessária a utilização de técnicas avançadas de Processamento de Linguagem Natural (NLP) e representação vetorial para transformar informações não estruturadas em conhecimento útil.

O presente projeto está inserido nesse cenário, propondo o desenvolvimento de uma prova de conceito de um sistema de recomendação de filmes baseado em embeddings e similaridade semântica.

1.2 Motivação

A motivação deste trabalho está relacionada à crescente importância dos sistemas de recomendação na personalização da experiência digital. Além disso, o projeto busca explorar a integração entre análise de sentimento, representação textual por embeddings e sistemas de recomendação, permitindo aplicar conceitos relevantes da área de Ciência de Dados em um problema prático. Outro fator motivador consiste no desafio de utilizar um dataset originalmente destinado à análise de sentimentos (IMDb 50K) para construir um sistema funcional de recomendação, exigindo integração com bases complementares e adaptação metodológica.

1.3 Justificativa

A relevância do projeto está associada à necessidade de desenvolver mecanismos capazes de recomendar conteúdos mais alinhados às preferências dos usuários, reduzindo o tempo de busca e aumentando a qualidade da experiência em plataformas digitais.

Do ponto de vista acadêmico, o trabalho permite aplicar técnicas de Processamento de Linguagem Natural, embeddings, similaridade semântica e sistemas de recomendação baseados em conteúdo. Além disso, a integração entre múltiplos datasets demonstra uma

abordagem prática para superar limitações estruturais dos dados disponíveis. A proposta também contribui para o entendimento de como modelos simples de recomendação podem evoluir para abordagens mais robustas por meio da incorporação de informações adicionais, como avaliações históricas dos usuários.

1.4 Objetivo Geral e Objetivos Específicos

1.4.1 Objetivo Geral

Desenvolver uma prova de conceito de um sistema de recomendação de filmes baseado em conteúdo, capaz de sugerir títulos a partir das preferências inferidas por avaliações textuais e informações estruturadas dos filmes.

1.4.2 Objetivos Específicos

- Realizar análise exploratória dos datasets IMDb e MovieLens;
- Realizar limpeza, normalização e preparação dos dados textuais;
- Construir um perfil de preferência do usuário utilizando embeddings gerados a partir de avaliações positivas;
- Integrar informações dos datasets MovieLens (movies, tags e ratings) para enriquecimento da recomendação;
- Gerar embeddings dos filmes utilizando técnicas de representação vetorial;
- Calcular similaridade semântica entre perfil do usuário e filmes;
- Gerar recomendações (Top-K) baseadas em similaridade;
- Avaliar o desempenho do modelo utilizando métricas como Precision@10 e similaridade média;
- Realizar ajustes no pipeline visando melhorar a qualidade das recomendações.

2. REFERENCIAL TEÓRICO

2.1 Sistemas de Recomendação

Sistemas de recomendação são técnicas computacionais desenvolvidas para sugerir itens relevantes aos usuários com base em suas preferências, comportamentos ou características dos próprios itens (RICCI et al., 2015; ZHANG et al., 2021). Esses sistemas são amplamente utilizados em plataformas digitais como serviços de streaming, comércio eletrônico e redes sociais, desempenhando papel fundamental na personalização da experiência do usuário. De forma geral, os sistemas de recomendação podem ser classificados em três categorias principais: filtragem colaborativa, recomendação baseada em conteúdo e abordagens híbridas (RICCI et al., 2015). A filtragem colaborativa utiliza padrões de interação entre usuários e itens, enquanto a recomendação baseada em conteúdo utiliza atributos dos próprios itens para identificar similaridades e sugerir novos conteúdos.

2.2 Recomendação Baseada em Conteúdo

A recomendação baseada em conteúdo consiste em sugerir itens similares àqueles que o usuário já demonstrou interesse (RICCI et al., 2015). Nesse tipo de abordagem, cada item é representado por um conjunto de características, e a recomendação é realizada a partir da comparação entre essas características e o perfil do usuário. No contexto deste projeto, essa abordagem foi escolhida devido à natureza dos dados disponíveis. O dataset IMDb fornece avaliações textuais capazes de inferir preferências, enquanto o MovieLens fornece atributos estruturados dos filmes, como gêneros, títulos e tags. Dessa forma, a recomendação baseada em conteúdo mostrou-se mais adequada do que abordagens colaborativas tradicionais.

2.3 Representação Vetorial e Embeddings

Para permitir a comparação entre textos, é necessário transformar dados não estruturados em representações numéricas (ZHANG et al., 2021).

Nesse contexto, utilizam-se embeddings, que são vetores densos capazes de capturar relações semânticas entre palavras, frases ou documentos. Embeddings permitem representar textos em um espaço vetorial no qual conteúdos semanticamente semelhantes ficam mais próximos entre si (REIMERS; GUREVYCH, 2019). Essa característica é

essencial para tarefas como classificação, busca semântica e sistemas de recomendação baseados em conteúdo.

2.4 Sentence Transformers e Similaridade Semântica

O modelo Sentence Transformers é uma abordagem baseada em redes neurais capaz de gerar embeddings de alta qualidade para sentenças e documentos (REIMERS; GUREVYCH, 2019). Esses modelos são amplamente utilizados em tarefas de similaridade semântica por produzirem representações vetoriais capazes de preservar significado textual. Após a geração dos embeddings, a similaridade entre dois vetores pode ser calculada utilizando métricas como a similaridade cosseno (Sentence Transformers, 2024), que mede o grau de proximidade entre vetores em um espaço semântico.

No presente projeto, o modelo Sentence Transformers foi utilizado tanto para representar avaliações dos usuários quanto para representar os filmes, permitindo compará-los em um mesmo espaço vetorial.

2.5 Integração de Dados e Abordagem Proposta

O projeto utiliza uma abordagem integrada, combinando dois datasets com funções complementares.

O dataset IMDb é utilizado para extrair o perfil do usuário por meio de avaliações textuais, enquanto o dataset MovieLens é utilizado como catálogo estruturado para recomendação de filmes específicos. Essa integração permite superar limitações presentes em cada dataset individualmente, possibilitando a construção de um sistema de recomendação enriquecido por informações semânticas e avaliações históricas.

2.6 Considerações sobre Prova de Conceito


Este trabalho adota uma abordagem de prova de conceito, conforme proposto pela disciplina.

O objetivo não consiste em desenvolver um sistema completo de recomendação, mas demonstrar a viabilidade da técnica proposta utilizando embeddings, similaridade semântica e integração entre datasets distintos. As métricas utilizadas, como Precision@10 e similaridade média, apresentam simplificações, porém são adequadas para validar o funcionamento do modelo. Os resultados obtidos indicam que a abordagem é capaz de gerar recomendações coerentes com preferências inferidas a partir de avaliações textuais.

3. METODOLOGIA

Nesta seção é descrita a metodologia utilizada para o desenvolvimento do sistema de recomendação proposto. O processo envolve desde a definição do problema e coleta dos dados até a avaliação do modelo e aplicação de ajustes para melhoria das recomendações. A metodologia adotada foi estruturada em etapas sequenciais, abrangendo preparação dos dados, geração de embeddings, cálculo de similaridade, avaliação do desempenho e otimização do pipeline. O fluxo metodológico utilizado no desenvolvimento do projeto é apresentado na Figura 1. Nas subseções seguintes são detalhadas as etapas descritas no fluxo metodológico.

Fluxo Metodológico Utilizado no Desenvolvimento do Projeto



3.1 Definição do Problema e Objetivos

O problema abordado neste trabalho consiste no desenvolvimento de um sistema capaz de recomendar filmes a partir das preferências inferidas por avaliações textuais dos usuários. Inicialmente, observou-se que o dataset IMDb 50K Movie Reviews contém informações sobre sentimento (positivo ou negativo), porém não possui identificadores suficientes para recomendação direta de filmes.

Dessa forma, tornou-se necessário integrar fontes complementares de dados para permitir a construção de um sistema de recomendação funcional. O objetivo do projeto consiste em desenvolver uma prova de conceito de recomendação baseada em conteúdo, utilizando embeddings para representar preferências dos usuários e características semânticas dos filmes.

3.2 Coleta de Dados

Para o desenvolvimento do projeto foram utilizados dois datasets distintos com funções complementares.

3.2.1 Dataset IMDb 50K Movie Reviews

Utilizado para construção do perfil do usuário a partir de avaliações textuais.

Características principais:

- aproximadamente 50 mil avaliações;
- classificação binária entre sentimentos positivos e negativos;
- textos em linguagem natural produzidos pelos usuários.

3.2.2 Dataset MovieLens

Utilizado como catálogo estruturado para recomendação.

- Foram utilizados os arquivos:
- movies.csv;
- tags.csv;
- ratings.csv.

Esses arquivos fornecem informações relacionadas a títulos, gêneros, tags e avaliações atribuídas pelos usuários.

A integração entre os datasets permitiu superar limitações individuais das bases, possibilitando construir um sistema de recomendação funcional.

3.3 Pré-processamento e Limpeza dos Dados

Foi realizada limpeza textual dos reviews do IMDb, incluindo:

- remoção de marcações HTML;
- remoção de caracteres especiais;
- normalização para letras minúsculas;
- remoção de espaços extras.

Além disso, foram utilizadas apenas avaliações classificadas como positivas para construção do perfil do usuário, reduzindo ruídos provenientes de avaliações negativas. Para o dataset MovieLens, realizou-se integração entre os arquivos `movies.csv` e `tags.csv`, criando o campo `movie_text`, responsável por combinar título, gêneros e tags em uma única representação textual. Essa abordagem permitiu transformar cada filme em uma entidade semanticamente comparável.

3.4 Construção do Perfil do Usuário

Após o pré-processamento, os dados foram organizados em dois fluxos principais. No primeiro fluxo, as avaliações positivas do IMDb foram transformadas em embeddings e posteriormente agregadas por meio da média, resultando no perfil do usuário. No segundo fluxo, os dados dos filmes passaram pela criação do campo `movie_text`, seguida da geração de embeddings para representação semântica. O perfil do usuário foi obtido pela média dos embeddings das avaliações positivas, resultando em um vetor de dimensão (1,384), representando as preferências inferidas a partir das avaliações.

3.5 Seleção e Implementação do Algoritmo

O principal algoritmo utilizado foi o modelo pré-treinado Sentence Transformers (all-MiniLM-L6-v2), responsável pela geração dos embeddings dos textos. Após a geração dos vetores, utilizou-se a métrica de similaridade cosseno para calcular a proximidade entre o perfil do usuário e os embeddings dos filmes. Os filmes com maiores valores de similaridade foram selecionados como recomendações finais.

3.6 Treinamento do Modelo

Nesta etapa foram gerados os embeddings das avaliações positivas do usuário e os embeddings dos filmes disponíveis no dataset MovieLens. Os embeddings dos filmes resultaram em uma matriz com dimensão (9742,384), sendo cada vetor responsável por representar semanticamente informações como título, gênero e tags associadas ao filme. Essa representação vetorial permitiu comparar usuários e filmes em um mesmo espaço semântico.

3.7 Avaliação do Desempenho

O desempenho do modelo foi avaliado utilizando métricas relacionadas à proximidade semântica e relevância das recomendações.

Foram utilizadas:

- Similaridade média, responsável por medir a proximidade entre o perfil do usuário e os filmes recomendados;
- Precision@10, utilizada para estimar a proporção de recomendações alinhadas aos gêneros esperados.

Os resultados do modelo baseline apresentaram:

- Precision@10 = 0,6;
- Similaridade média $\approx$ 0,51.

Esses resultados indicaram capacidade do modelo em gerar recomendações coerentes com as preferências inferidas.

3.8 Otimização e Ajustes

Após análise crítica do modelo baseline, foram identificadas limitações relacionadas à ausência de informações sobre qualidade dos filmes e à dependência exclusiva de similaridade semântica.

Como ajuste, foram incorporadas informações provenientes do arquivo ratings.csv do MovieLens.

Foram calculadas:

- média das avaliações dos filmes (rating_mean);
- quantidade total de avaliações (rating_count).

Posteriormente, aplicaram-se filtros considerando apenas filmes com:

- nota média maior ou igual a 3,5;
- pelo menos 20 avaliações registradas.

Após os ajustes, o modelo apresentou:

- Precision@10 = 0,6;
- Similaridade média $\approx$ 0,48.

Embora tenha ocorrido redução na similaridade média, o modelo passou a considerar também a qualidade dos filmes, tornando as recomendações potencialmente mais relevantes.

3.9 Implantação e Monitoramento

O modelo foi desenvolvido em ambiente Google Colab, permitindo reprodução completa do pipeline experimental.

Por tratar-se de uma prova de conceito, não foi realizada implantação em ambiente produtivo. Como evolução futura, o sistema poderá ser disponibilizado por meio de aplicações web, APIs ou integração com plataformas de recomendação. Além disso, recomenda-se monitoramento contínuo baseado em métricas de desempenho e feedback dos usuários, permitindo ajustes e refinamentos nas recomendações produzidas.

4. RESULTADOS

Esta seção apresenta os resultados obtidos pelo sistema de recomendação desenvolvido, incluindo métricas de desempenho, comparação entre versões do modelo e discussão sobre os resultados alcançados.

4.1 Resultados do Modelo Baseline

Inicialmente, foi avaliado o modelo desenvolvido na etapa inicial (baseline), no qual as recomendações eram geradas exclusivamente com base na similaridade semântica entre o perfil do usuário e os filmes.

Os resultados obtidos foram:

- $\text{Precision@10} = 0,6$;
- Similaridade média $\approx 0,51$.

Além disso, os filmes recomendados apresentaram valores de similaridade variando aproximadamente entre 0,49 e 0,55, indicando proximidade semântica moderada entre o perfil inferido e os itens sugeridos.

Observou-se predominância de filmes pertencentes ao gênero Drama entre as recomendações geradas, indicando coerência com o perfil construído a partir das avaliações positivas.

4.2 Resultados Após Ajustes do Modelo

Após identificação das limitações do modelo baseline, foi incorporada ao pipeline a informação proveniente do arquivo ratings.csv do dataset MovieLens.

O ajuste consistiu na utilização de filtros considerando:

- nota média dos filmes ($\text{rating_mean} \geq 3.5$);
- quantidade mínima de avaliações ($\text{rating_count} \geq 20$).

Após aplicação dos filtros, o modelo apresentou os seguintes resultados:

- $\text{Precision@10} = 0,6$;
- Similaridade média $\approx 0,48$.

Os resultados indicam manutenção da métrica Precision@10 , demonstrando que o modelo preservou sua capacidade de recomendar filmes alinhados ao perfil esperado.

4.3 Comparação entre Modelo Baseline e Modelo Ajustado

A seguir, apresenta-se a comparação entre os resultados obtidos antes e após os ajustes realizados.




Figura 1 — Comparação da similaridade média entre o modelo baseline e o modelo ajustado.

Observa-se que a inclusão das avaliações históricas dos usuários não alterou a métrica Precision@10 , indicando que o modelo manteve sua capacidade de recomendar filmes alinhados ao perfil inferido do usuário.

Por outro lado, verificou-se uma leve redução na similaridade média, passando de aproximadamente 0,51 para 0,48. Essa redução pode ser explicada pela restrição do espaço de busca após a aplicação dos filtros de qualidade ($\text{rating_mean} \geq 3,5$ e $\text{rating_count} \geq 20$).

Apesar da redução na similaridade média, o ajuste realizado contribuiu para melhorar potencialmente a qualidade das recomendações, uma vez que o modelo passou a priorizar filmes melhor avaliados pelos usuários. Dessa forma, o sistema evoluiu de uma abordagem exclusivamente baseada em similaridade semântica para uma abordagem mais robusta, considerando simultaneamente similaridade e qualidade dos filmes.

4.4 Análise das Métricas

4.4.1 Similaridade Média

A similaridade média mede o grau de proximidade semântica entre o perfil inferido do usuário e os filmes recomendados. Embora tenha ocorrido redução da similaridade média após os ajustes, isso não necessariamente representa pior desempenho. A diminuição ocorreu devido à priorização de filmes com melhor avaliação, tornando o sistema potencialmente mais robusto do ponto de vista prático.

4.4.2 Precision@10

A métrica Precision@10 apresentou valor igual a 0,6 tanto no modelo baseline quanto após os ajustes. Esse resultado indica que aproximadamente 60% das recomendações permaneceram alinhadas com os gêneros considerados relevantes para o perfil do usuário. A estabilidade da métrica demonstra capacidade do sistema em preservar coerência nas recomendações mesmo após modificações no pipeline.

4.5 Discussão dos Resultados

Os resultados demonstram que a melhoria de um sistema de recomendação não está necessariamente associada ao aumento das métricas de similaridade. A incorporação das avaliações do MovieLens permitiu reduzir a probabilidade de recomendar filmes pouco relevantes ou mal avaliados, tornando o sistema mais próximo de aplicações reais. Assim, o modelo evoluiu de uma abordagem exclusivamente baseada em similaridade semântica para uma abordagem híbrida, considerando simultaneamente:

- similaridade entre perfil e filmes;
- qualidade dos filmes medida pelas avaliações históricas.

4.6 Limitações Observadas

Apesar dos resultados positivos, algumas limitações permanecem presentes:

- utilização de métricas simplificadas para avaliação;
- ausência de validação com usuários reais;
- limitação na quantidade de tags disponíveis para determinados filmes;
- utilização de perfil médio do usuário, podendo reduzir nuances individuais;

5. CONCLUSÕES E TRABALHOS FUTUROS

5.1 Resumo dos Principais Resultados

O presente trabalho teve como objetivo desenvolver uma prova de conceito de um sistema de recomendação de filmes baseado em conteúdo, utilizando embeddings e similaridade semântica para inferir preferências dos usuários a partir de avaliações textuais.

Inicialmente, foi realizada análise exploratória e preparação dos dados provenientes dos datasets IMDb e MovieLens. Em seguida, foram gerados embeddings tanto para representar o perfil do usuário quanto para representar semanticamente os filmes disponíveis.

Os resultados demonstraram que o modelo foi capaz de gerar recomendações coerentes com as preferências inferidas, obtendo Precision@10 igual a 0,6.

Posteriormente, ajustes foram incorporados ao pipeline por meio da utilização das avaliações históricas do MovieLens (ratings.csv), permitindo considerar simultaneamente similaridade semântica e qualidade dos filmes.

Embora a similaridade média tenha reduzido levemente após os ajustes, o modelo tornou-se potencialmente mais robusto, priorizando recomendações de filmes melhor avaliados.

Assim, os resultados obtidos indicam que a abordagem proposta é viável para construção de sistemas de recomendação baseados em conteúdo.

5.2 Contribuições do Projeto

O projeto contribuiu para aplicação prática de conceitos relacionados a:

- Processamento de Linguagem Natural (NLP);
- representação vetorial por embeddings;
- sistemas de recomendação baseados em conteúdo;
- integração entre múltiplos datasets;
- avaliação e otimização de modelos.

Além disso, o trabalho demonstrou como dados originalmente destinados à análise de sentimento podem ser adaptados para construção de sistemas de recomendação, mediante integração com bases complementares.

5.3 Limitações Identificadas

Apesar dos resultados satisfatórios, foram identificadas algumas limitações:

- ausência de validação utilizando usuários reais;
- utilização de métricas simplificadas;
- limitação das tags disponíveis para determinados filmes;
- ausência de comparação com algoritmos colaborativos ou híbridos;
- simplificação do perfil do usuário por meio da média dos embeddings.

Essas limitações indicam possibilidades de evolução do sistema desenvolvido.

5.4 Impacto Prático

Os resultados obtidos demonstram potencial aplicação em plataformas digitais que necessitam recomendar conteúdos personalizados.

Sistemas semelhantes podem contribuir para:

- aumento do engajamento dos usuários;
- melhoria da experiência em plataformas de streaming;
- redução do tempo necessário para descoberta de conteúdos relevantes;
- aumento da satisfação do usuário por meio de recomendações mais alinhadas às preferências individuais.

Embora desenvolvido como prova de conceito, o modelo apresenta potencial para expansão em cenários reais.

5.5 Trabalhos Futuros

Como continuidade do projeto, sugerem-se as seguintes melhorias:

5.5.1 Melhorias Técnicas

Implementação de algoritmos mais avançados, incluindo:

- modelos híbridos de recomendação;
- técnicas baseadas em aprendizado profundo (Deep Learning);
- sistemas colaborativos complementares.

5.5.2 Testes e Validações Adicionais

Realização de avaliações utilizando usuários reais para medir qualidade percebida das recomendações.

Além disso, recomenda-se utilização de métricas adicionais, tais como:

- Recall;
- F1-Score;
- NDCG;
- RMSE;
- MAE.

5.5.3 Expansão dos Dados

Integração com novas fontes de informação, incluindo:

- histórico de navegação;
- avaliações adicionais;
- dados comportamentais;
- informações provenientes de plataformas externas.

5.5.4 Escalabilidade e Implantação

Como evolução futura, recomenda-se disponibilizar o sistema por meio de aplicações web ou APIs, permitindo utilização em ambientes produtivos.

Além disso, seria necessário desenvolver estratégias de monitoramento contínuo para atualização do modelo e melhoria das recomendações ao longo do tempo.

6. CONSIDERAÇÕES FINAIS

Os resultados obtidos indicam que o objetivo principal do trabalho foi alcançado, demonstrando a viabilidade da utilização de embeddings e similaridade semântica para recomendação de filmes baseada em conteúdo.

A integração entre múltiplos datasets mostrou-se fundamental para superar limitações estruturais dos dados, permitindo transformar um problema inicialmente relacionado à análise de sentimento em um sistema funcional de recomendação.

7. REFERÊNCIAS

HARPER, F. Maxwell; KONSTAN, Joseph A. The MovieLens datasets: history and context. *ACM Transactions on Interactive Intelligent Systems*, New York, v. 5, n. 4, p. 19:1–19:19, 2015. DOI: <https://doi.org/10.1145/2827872>.

REIMERS, Nils; GUREVYCH, Iryna. Sentence-BERT: sentence embeddings using Siamese BERT-networks. In: *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing*. Hong Kong: Association for Computational Linguistics, 2019. Disponível em: <https://arxiv.org/abs/1908.10084>. Acesso em: 19 maio 2026.

RICCI, Francesco; ROKACH, Lior; SHAPIRA, Bracha. Introduction to recommender systems handbook. In: RICCI, Francesco; ROKACH, Lior; SHAPIRA, Bracha; KANTOR, Paul (org.). *Recommender Systems Handbook*. Boston: Springer, 2011. p. 1–35. DOI: https://doi.org/10.1007/978-0-387-85820-3_1.

SENTENCE TRANSFORMERS. Documentation. Disponível em: <https://www.sbert.net/>.

ZHANG, Shuai et al. Deep learning based recommender system: a survey and new perspectives. *ACM Computing Surveys*, New York, v. 54, n. 1, p. 1–38, 2021. DOI: <https://doi.org/10.1145/3466811>.

8. APÊNDICES

APÊNDICE A — LINK DO VÍDEO DE APRESENTAÇÃO

O vídeo de apresentação do projeto contém resumo do problema, metodologia utilizada, pipeline desenvolvido, resultados obtidos e principais conclusões.

Link do vídeo:

Disponível em:

<https://www.youtube.com/watch?v=4VFgVdHtRuY>

APÊNDICE B — REPOSITÓRIO GITHUB

O código-fonte utilizado para desenvolvimento do projeto, incluindo notebooks, scripts, artefatos e documentação complementar, encontra-se disponível no repositório:

Disponível em:

<https://github.com/felipeclarindo/projeto-aplicado-3>

APÊNDICE C — DATASETS UTILIZADOS

Para construção do sistema de recomendação foram utilizados os seguintes datasets:

IMDb Dataset of 50K Movie Reviews

Dataset utilizado para construção do perfil do usuário por meio das avaliações textuais.

Disponível em:

<https://www.kaggle.com/datasets/lakshmi25npathi/imdb-dataset-of-50k-movie-reviews>

MovieLens Dataset (ml-latest-small)

Dataset utilizado para obtenção de filmes, gêneros, tags e avaliações históricas dos usuários.

Disponível em:

<https://grouplens.org/datasets/movielens/latest/>